

项目评测 · 系统改进 · 技术资料

MyAI 项目技术文档

基于 7.17 原始项目与 MyAI 调优版本的完整复盘

原始版本 → 当前实现 → 评测体系 → 改进路线 → 技术说明

生成日期：2026-08-29

可编辑 Word 版 / 可打印 PDF 版

阅读导航

本手册严格区分：7.17 原始项目、你已经调优的 MyAI、尚未实现的下一阶段方案。语雀/Git 资料只作为方法论依据。

1. 第一部分：项目架构、功能、技术方案与优化复盘
2. 第二部分：评测指标、实际结果、参数调优与改进路线
3. 第三部分：60 个常见技术问题及设计说明
4. 第四部分：项目技术速查

当前结果说明：目前只能报告小规模离线召回结果和 3 题端到端冒烟测试，不能声称整个系统准确率 100%。

第 1 部分 项目架构与功能说明

一、项目名称

推荐名称：

基于混合检索与重排序的企业金融报告 RAG 问答助手

不要把当前项目描述成已经完整覆盖金融和政务。原始页面虽然存在“政务问答”名称和政务数据，但原始 RAG 构建脚本实际只索引蓝天旅游报告；当前 MyAI 真正索引的是 10 份企业金融报告。

二、版本演进

V0：7.17 根目录接口演示

- FastAPI、Gradio/Streamlit 前后端原型；
- 后端主要通过延时和固定文本模拟回答；
- 用来验证页面、接口和会话，不是真实 RAG。

V1：7.17/11 原始 RAG

- 只索引 18_蓝天旅游有限公司_report.pdf；
- chunk_size=200、chunk_overlap=50；
- 26 个切片，平均约 170 字；
- BGE-small 中文 Embedding；
- FAISS Top10；
- SiliconFlow bge-reranker-v2-m3 重排到 Top3；
- DeepSeek-R1-Qwen3-8B 生成答案；
- Streamlit 展示答案和来源切片。

V2：你已经调优的 MyAI

- 从 1 份报告扩展到 10 份；
- 切片改成 500/80，提高财务指标上下文完整度；
- 索引清理为 112 个唯一切片；

- 修复曾经出现的 1120 条记录仅 112 条唯一正文、正文绑定多家公司的错误；
- 增加 BM25 关键词召回；
- 增加公司名称识别和元数据过滤；
- 增加内容标准化去重；
- 保留 BGE Reranker Top3；
- 增加相关性拒答、数字/英文实体规则校验；
- 增加 FAQ、反馈和 few-shot 闭环雏形；
- 引用从短切片扩展为完整 PDF 页面，显示公司、文件和页码。

V3：下一轮优化

- 中文 BM25 分词；
- Dense 与 BM25 使用 RRF 融合；
- 保存 Dense、BM25、Reranker 的 rank 和 score；
- Golden Set 扩充并冻结；
- 阈值、Chunk、TopK 消融实验；
- 修复 FAQ/few-shot 问题；
- 异步请求、日志、追踪和线上监控。

三、系统架构

离线：

10 份企业 PDF

→ PyPDFLoader 按页解析

→ 清洗公司名和元数据

→ RecursiveCharacterTextSplitter (500/80)

→ BGE-small-zh-v1.5 生成 512 维向量

→ FAISS IndexFlatL2

→ 保存页面、公司、文件和 BM25 语料

在线：

用户问题

→ 识别问题中出现的公司

→ FAISS Dense Top10

→ BM25 Top20

→ 公司过滤、合并、正文去重

→ SiliconFlow BGE Reranker Top3

- 相关性检查，不相关则拒答
- DeepSeek-R1-Qwen3-8B 低温度生成
- 数字/实体规则检查
- 返回答案和完整 PDF 页面引用

一句话：

这是 Retrieve-Rerank-Generate 架构。粗召回追求找全，Cross-Encoder 精排追求把证据放到前面，生成阶段只使用 Top3 上下文，并通过原始 PDF 页提供可追溯证据。

四、项目摘要

我在一个单文档 RAG 实训原型上，搭建并调优了企业金融报告问答助手。系统离线解析 10 份企业 PDF，按 500 字、80 字重叠切片，使用 BGE-small 生成 512 维向量并存入 FAISS；在线结合 Dense 和 BM25 召回，再用 BGE Reranker 精排到 Top3，由 Qwen3-8B 生成并返回文件和页码。项目中我重点修复了重复索引与跨公司错配，并补充了公司过滤、拒答、校验、用户反馈和分层评测。第一版 27 题离线评测显示 Dense Hit@10 为 1.000，而原 BM25 中文分词 Hit@10 只有 0.370，换成字符分词后达到 1.000。

五、技术架构说明

这个项目的原始版本是我提供的 7.17 实训项目，其中真实 RAG 只索引一份蓝天旅游 PDF，使用 200/50 切片、BGE Dense Top10、Reranker Top3 和云端大模型回答。我在此基础上扩展为 10 份企业金融报告，并把切片调整为 500/80，让公司、年份、指标、数值和单位尽量位于同一上下文。多文档扩展后，我遇到过一个很典型的问题：索引里有 1120 条记录，却只有 112 条唯一正文，同一正文还被绑定到 10 家公司，造成回答看似正确但引用串公司。我通过统计正文 hash 和公司元数据定位问题，修复构建脚本，让每份 PDF 只处理一次，并按公司加标准化正文去重。重建后得到 112 条唯一切片，跨公司元数据错配降为 0。在线部分我加入了 Dense 与 BM25 两路召回、公司元数据过滤、内容去重和 BGE Reranker，最终保留 Top3。生成使用低 temperature，并增加相关性拒答、数字和实体检查；前端展示完整 PDF 页面，而不是半句话切片。我没有只靠 Demo 判断效果，而是建立了 Golden Set 和离线评测脚本。第一版有 32 题，其中 27 题可回答。结果显示 BGE Dense 的 Hit@10 为 1.000、MRR 为 0.910；当前 BM25 因为中文空白分词，Hit@10 只有 0.370。使用字符 unigram+bigram 后 BM25 Hit@10 达到 1.000、MRR 达到 0.932；再与 Dense 做 RRF 时 Hit@3 达到

1.000。端到端目前只跑了 3 题冒烟测试，所以我不会虚构整体准确率。下一步要扩充并冻结测试集、实现 RRF、保留 Reranker 分数并校准拒答阈值。

六、问题定位与改进复盘

案例一：重复索引与跨公司错配

- 问题背景：扩展到多份企业报告后，出现回答数字正确但引用公司错误。
- 优化目标：判断问题出在数据、检索、重排、生成还是前端映射。
- 处理过程：分别打印原始召回和最终重排结果；统计索引条数、唯一正文数和公司标签；发现 1120 条记录仅 112 条唯一正文；修复循环逻辑、公司名清洗与正文去重；重建索引并做多公司回归。
- 验证结果：112 条记录全部唯一，跨公司元数据错配为 0，四条人工回归的答案和引用公司均正确。

案例二：中文 BM25 问题

- 问题背景：系统宣称使用混合检索，但无法量化 BM25 到底有没有贡献。
- 优化目标：单独测试 Dense、BM25 和融合方案。
- 处理过程：建立 27 条可回答题，按 PDF 页面计算 Hit@K、Recall@K 和 MRR；复现当前空白分词，再实现字符 unigram+bigram 基线，并离线模拟 RRF。
- 验证结果：空白分词 BM25 Hit@10 仅 0.370，字符分词后达到 1.000；字符 BM25 加 Dense RRF 的 Hit@3 达到 1.000。结论是混合检索概念没有错，问题在中文分词和融合实现。

七、项目功能与成果

当前已验证

企业金融报告 RAG 智能问答助手 | Python / FastAPI / Streamlit / FAISS / BGE / BM25

- 在单文档 RAG 原型上扩展 10 份企业金融报告，完成 PDF 解析、500/80 切片、BGE-small 512 维向量化及 FAISS 索引构建；
- 定位并修复索引十倍重复与跨公司元数据错配，将 1120 条错误记录重建为 112 条唯一切片，并加入公司过滤与完整 PDF 页引用；

- 构建 Dense + BM25 + BGE Reranker 检索链路，加入相关性拒答、答案规则校验、FAQ 与反馈闭环雏形；
- 建立 32 题评测集及页面级召回评测工具；27 条可回答题上，Dense Hit@10 为 1.000，发现原中文 BM25 Hit@10 仅 0.370，字符分词方案提升至 1.000。

尚未完成或不能宣称的能力

- “系统准确率 100%”；
- “Reranker 已完成微调”；
- “支持百万级数据与高并发”；
- “完整金融政务双域知识库”；
- “大模型完全本地部署”；
- “线上反馈闭环已经产生显著提升”。

八、项目技术亮点

1. 数据问题定位：不是只调用模型 API，而是能查出索引和元数据错误。
2. 分层检索：Dense、BM25、Reranker 职责清晰。
3. 可追溯引用：模型用 Chunk，用户核对完整 PDF 页。
4. 分层评测：召回、重排、答案、拒答、延迟分别测。
5. 诚实实验：明确小样本结果与尚未完成内容。

第 2 部分 评测、诊断、调参与改进

零、如何把语雀/Git 资料落到当前项目

语雀材料不是孤立的理论，和 MyAI 可以一一对应：

语雀主题	核心观点	MyAI 现状	下一步落地
RAG	外部知识检索后再生成	已实现	加强数据版本与引用验证
RAG 2.0	Dense、Sparse、Hybrid、Rerank	Dense、BM25、Reranker 已存在	修中文分词、RRF 和阶段日志
向量检索	Flat/HNSW/IVF/PQ 按规模选择	112 条使用 FAISS Flat	数据扩大后再换 ANN/向量库
评估	检索、生成、忠实度分层评测	原来主要靠网页 Demo	建 Golden Set 和自动评测
Qwen3 Embedding	指令感知、多尺寸向量模型	当前使用 BGE-small	作为候选模型做消融实验
Qwen3 Reranking	Query-Doc 联合打分、Hard Negative	当前调用 BGE Reranker API	保存分数，积累难负例后再微调

项目说明可以这样写：

我没有直接把资料里的所有新模型堆进项目，而是先把知识点映射成可验证的工程假设。例如 RAG 2.0 强调混合检索，我就分别测 Dense 和 BM25，发现问题不在混合检索思路，而在中文空白分词；向量检索资料强调按规模选索引，所以 112 条数据继续用精确 Flat，而不是为了技术名词强上 Milvus。

一、为什么必须分层评测

最终答案错，不一定是大模型错：

现象	主要检查对象
原始 TopK 没有标准页	数据、切片、Embedding、Query、BM25

现象	主要检查对象
原始 TopK 有，Top3 没有	融合或 Reranker
Top3 正确，答案错误	Prompt、模型、计算、上下文利用
答案正确，引用错误	元数据、引用映射、父子切片
无答案却强答	阈值、拒答、幻觉控制
结果正确但很慢	模型加载、同步请求、Reranker、LLM

所以评测要分成：数据质量、粗召回、精排、生成、拒答、端到端和工程性能。

二、怎么知道召回了什么

每次请求至少记录：

```
{
  "trace_id": "...",
  "question": "...",
  "mentioned_companies": [...],
  "dense_topk": [{"file": "...", "page": 1, "rank": 1, "distance": 0.31}],
  "bm25_topk": [{"file": "...", "page": 1, "rank": 1, "score": 8.7}],
  "fused_topk": [{"file": "...", "page": 1, "rank": 1, "rrf_score": 0.032}],
  "reranked_top3": [{"file": "...", "page": 1, "rank": 1, "score": 0.91}],
  "answer": "...",
  "latency_ms": {"dense": 18, "bm25": 5, "rerank": 430, "llm": 9200}
}
```

网页最终显示的 `source_documents` 只是 Reranker 后的最终引用，不等于 FAISS 或 BM25 原始召回。

要判断召回问题，必须看各阶段中间结果。

三、Golden Set 怎么建

每题至少标注：

- question：真实问题或改写；
- answerable：知识库能否回答；
- answer_checks 或标准答案；
- gold_pages 或 gold_chunk_ids；
- category：事实、事件、比较、治理、无答案等；
- difficulty：easy/medium/hard；

- notes：单位、歧义、异常说明。

建议最终规模：

- 开发集 100-200 题，用于调参；
- 冻结测试集 100-200 题，只在版本定稿时运行；
- 15%-25%无答案题；
- 覆盖错别字、简称、口语改写、多文档比较、时间限制和 Prompt Injection。

当前 32 题只是第一版评测基线，不是最终生产测试集。

四、召回指标公式

Hit@K

$\text{Hit@K} = \text{TopK 至少命中一个标准页面的问题数} / \text{问题总数}$

适合每题只有一个核心答案页的问答系统。

Recall@K

$\text{Recall@K}(q) = \text{TopK 找到的相关页面数} / \text{该问题全部相关页面数}$

例如多公司比较需要 2 页，Top3 只找到 1 页， $\text{Recall@3}=1/2$ 。

Precision@K

$\text{Precision@K}(q) = \text{TopK 相关页面数} / K$

召回高、精度低表示找得全但噪声多。

MRR

$\text{MRR} = \text{mean}(1 / \text{第一个相关页面排名})$

排名为 1、2、5、未命中时： $(1 + 1/2 + 1/5 + 0) / 4 = 0.425$ 。

NDCG@K

当页面分为“完全相关、部分相关、不相关”时使用，既考虑相关等级，也考虑高相关页面是否排在前面。

五、答案与拒答指标

数值准确率

先统一单位，再比较：

(公司, 年份, 指标, 数值, 单位)

1 亿元 = 10 000 万元 = 100 000 000 元。只比较字符串会把等价答案误判为错误。

短答案

- Exact Match；
- Token Precision/Recall/F1；
- 结构化字段正确率。

长答案

- Correctness：结论是否正确；
- Completeness：关键点是否完整；
- Relevance：是否真正回答问题；
- Faithfulness：每个事实是否被上下文支持。

Faithfulness = 被引用上下文支持的原子 Claim 数 / 全部原子 Claim 数

BLEU/ROUGE 只能衡量文字重合，不能可靠判断金融事实正确性。

拒答

- Refusal Precision：所有拒答中真正无答案的比例；
- Refusal Recall：所有无答案题中成功拒答的比例；
- Refusal F1；
- 无答案幻觉率：无答案却编造内容的比例。

六、已经跑出的离线评测

数据：27 条可回答题，按 PDF 页面去重后评测。

当前空白分词

方法	Hit@1	Hit@3	Hit@5	Hit@10	MRR@10
BM25	0.148	0.185	0.259	0.370	0.189
BGE Dense	0.852	0.963	1.000	1.000	0.910
RRF 模拟	0.333	0.519	0.704	0.926	0.488

结论：当前 BM25 对中文问题几乎没有可靠贡献，还会在 RRF 模拟中拖累 Dense。原因是默认按空格分词，而 PDF 中文字被整段当成很少的长 Token。

中文字符 unigram+bigram

方法	Hit@1	Hit@3	Hit@5	Hit@10	MRR@10
BM25	0.889	0.963	0.963	1.000	0.932
BGE Dense	0.852	0.963	1.000	1.000	0.910
RRF 模拟	0.852	1.000	1.000	1.000	0.920

结论：

- 中文分词使 BM25 Hit@10 从 0.370 提高到 1.000；
- BM25 MRR 从 0.189 提高到 0.932；
- RRF Hit@3 从 0.519 提高到 1.000；
- 本题集上字符 BM25 的 MRR 略高于 RRF，说明融合不是自动优于单路，仍需看指标和 Bad Case；
- 数据量只有 27 条可答题，结果是开发结论，不是最终泛化结论。

端到端冒烟测试

- 3 题；
- Answer Accuracy：1.000；
- Citation Hit Rate：1.000；
- Citation Recall：1.000；

- End-to-End Correct Rate : 1.000 ;
- 平均延迟 : 约 10.49 秒。

三题太少，只能证明评测链路可用，不能写成整体准确率 100%。

七、每部分为什么这样做、参数怎么调

1. PDF 解析

为什么 PyPDFLoader：当前报告是可复制文本 PDF，可以按页抽取并保留页码、source 和 total_pages。

问题：

- 表格行列可能被打乱；
- 扫描件需要 OCR；
- 图表数字不会自然变成结构化文本；
- 页眉页脚可能制造噪声。

下一步：段落走文本切片；表格转换成 Markdown/JSON；扫描页 OCR；图表用视觉模型；所有内容保留页码与表名。

2. Chunk 500/80

原始 200/50 容易把公司、年份、指标、数值和解释切开。500/80 更可能保留完整财务事实，重叠率约 16%。

不能说 500 一定最优，应测试：

Chunk	Overlap	观察指标
200	50	Recall、MRR、答案完整性
300	50	同上
500	80	当前基线
800	120	上下文完整度和噪声
结构切片	动态	表格、标题和段落边界

推荐父子切片：200-300 字小块检索，命中后把父段落或完整页给生成模型。

3. BGE-small-zh-v1.5

为什么：中文检索能力与 Mac 资源成本平衡，512 维、模型较小，112 个切片检索足够快。

要实验：

- Query 是否添加中文检索指令；
- `normalize_embeddings=True/False`；
- BGE-small/base/M3 或 Qwen3-Embedding-0.6B；
- Recall@5/10、MRR、编码耗时、内存和索引大小。

4. FAISS IndexFlatL2

为什么：只有 112 个向量，Flat 是精确搜索，没有近似检索损失，维护成本最低。

扩展后再考虑：

- HNSW：M、`efConstruction`、`efSearch`；
- IVF：`nlist`、`nprobe`；
- PQ：压缩率和量化误差；
- Milvus/Qdrant：动态更新、过滤、权限和多实例服务。

5. BM25

为什么：公司名、年份、金额和专业名词需要精确匹配，Dense 擅长语义但可能忽略字面细节。

当前最大问题：中文默认空白分词。下一步可选：

- jieba + 财务词典；
- 字符 unigram+bigram；
- Elasticsearch/OpenSearch 中文分析器。

参数：

- `k1` 控制词频饱和，一般从 1.2-2.0 搜索；

- b 控制文档长度惩罚，一般从 0.5-0.9 搜索；
- 用开发集 MRR 和 Hit@K 选，不凭感觉。

6. RRF 融合

BM25 分数与向量距离不在同一尺度，不能直接相加。RRF 只使用排名：

$$\text{RRF}(d) = \sum 1 / (c + \text{rank}_i(d))$$

常用 $c=60$ ，应测试 20/40/60/80。RRF 提升稳健性，但本题集上不一定提升 Top1，因此要结合 Reranker 和 Bad Case 分析。

7. Reranker

Embedding 双编码器快，适合粗召回；Cross-Encoder 联合读取 Query 和 Document，更准但更慢，适合几十条候选精排。

当前 Top3 是合理起点，但要测试 Top1/3/5。必须保留 `relevance_score`，否则无法：

- 判断 Reranker 是否改善排名；
- 校准拒答阈值；
- 分析高分错例；
- 监控分数漂移。

8. 拒答阈值 0.5

当前用 Top3 平均 Embedding 相似度并设置 0.5，没有开发集校准。正确方法：

1. 准备可回答与无答案题；
2. 保存 Top1、Top3 均值、最大分和 Reranker 分；
3. 扫描阈值；
4. 画 Precision-Recall 或 ROC；
5. 根据业务选择误答成本与拒答成本。

金融场景通常宁可多拒答，也不要编造财务数字。

9. 生成参数

- temperature=0.1：事实问答追求稳定；
- max_tokens=1024：足够回答，但应根据真实答案长度减少成本；
- Top3 上下文：控制噪声和 Token；
- 3 次重试：提高网络稳定性，但可能放大延迟。

需要增加：明确引用格式、单位规范、无证据拒答、Prompt Injection 防护和计算步骤校验。

八、当前代码仍需修复

P0

1. BM25 中文分词；
2. 实现 RRF，而非简单拼接；
3. Reranker 返回并保存分数；
4. 将阈值改为开发集校准结果；
5. 扩充并冻结 Golden Set；
6. 自动输出每阶段 rank、score 和耗时。

P1

1. FAQ 按问题去重，失败答案不缓存；
2. few_shot_text 当前构建后没有插入最终 Prompt；
3. few-shot 筛选时 timestamp 字段丢失，所谓“最新 5 条”排序无效；
4. validate_answer 重复提取数字，只做字符串匹配，不能判断语义支持；
5. async 路由内部使用同步 requests，会阻塞事件循环；
6. FAQ、Embedding、索引都应绑定知识库版本。

P2

1. 表格与结构感知解析；
2. Query Rewrite 和多跳分解；

- 3. Hard Negative 微调 Reranker ；
- 4. LLM Judge 加人工抽检 ；
- 5. Trace ID、p95/p99、错误率、Token 和成本监控 ；
- 6. 权限、租户隔离与 Prompt Injection 防护。

九、推荐实验表

版本	变化	Hit@10	MRR@10	Rerank Recall@3	Answer Accuracy	Faithfulness	p95
V2 Baseline	当前 MyAI	待完整测	待完整测	待测	待测	待测	待测
V2.1	中文 BM25	已测 1.000	已测 0.932	-	待测	待测	待测
V2.2	中文 BM25 + RRF	已测 1.000	已测 0.920	待接入	待测	待测	待测
V2.3	+保存 Reranker 分数	待测	待测	待测	待测	待测	待测
V2.4	+阈值校准	同上	同上	同上	待测	待测	待测

“待测”必须保留到真正跑完，不能为了展示填一个想象数字。

十、Qwen3 Embedding/Reranking 知识怎么用于项目

语雀资料中介绍了 Qwen3 Embedding 与 Reranking 的多种尺寸和训练思想。技术重点不是背模型名字，而是理解它们解决什么问题。

1. Instruction-aware Embedding

同一句文本用于“相似句搜索”“问答检索”“分类”时，理想表示可能不同。Instruction-aware 模型把任务描述也作为输入，让 Embedding 知道当前目标是“用中文短问题检索金融报告段落”。

在 MyAI 中应测试：

无指令：滨江公司的营业收入是多少？

有指令：为这个问题生成表示，以检索能够回答问题的企业金融报告段落：滨江公司的营业收入是多少？

只对 Query 加指令，文档保持原文；比较 Recall@5/10、MRR、编码延迟和缓存方式。

2. InfoNCE 与对比学习

训练目标是让 Query 靠近 Positive、远离 Negative。一个 batch 中的其他文档可作为 in-batch negative：

$$\text{loss} = -\log \exp(\text{sim}(q, p+)/\tau) / \sum \exp(\text{sim}(q, p_-i)/\tau)$$

温度 τ 越小，模型越强调相似度差异，但过小可能训练不稳定。

3. Hard Negative 为什么重要

随机负例太容易，模型学不到细粒度区别。金融报告中最有价值的 Hard Negative 是：

- 指标相同但公司不同；
- 公司相同但年份不同；
- 营业收入与净利润混淆；
- 资产负债率与负债比率相似；
- 页面主题相关但不含最终数值。

可以从当前 Dense/BM25 Top20 中排除标准页后自动采样，再人工复核。

4. Embedding 模型如何比较

不能只看公开 MTEB 排名。项目内要比较：

- Hit@K、Recall@K、MRR；
- 512/1024/更高维向量的内存；
- Mac CPU/MPS 编码时间；
- 索引构建耗时；
- 中文金融实体和单位的 Bad Case。

5. Reranker 相关性打分

Reranker 联合读取 Query 和候选文档，学习“这段文档是否能回答这个问题”，比单独向量相似度更细致。语雀材料中的 yes/no 相关性思想，本质上也是把相关性转成可比较分数。

在 MyAI 中，第一步不是立刻微调，而是先保留 API 返回的 `relevance_score`，测清楚：

- 重排前后 MRR 变化；
- 正例从 Top10 进入 Top3 的比例；
- 正例被错误排出的比例；
- 分数在可答题和无答案题上的分布。

有足够反馈数据后，才考虑用 query-positive-hard negative 做领域微调。

十一、从评测到改进的闭环

收集真实问题

- 人工标注答案与标准页
- 分成开发集和冻结测试集
- 跑每阶段 rank/score
- 按 Bad Case 分类
- 一次修改一个变量
- 在开发集调参
- 在冻结测试集确认
- 灰度上线
- 线上点踩/无结果问题回流

Bad Case 标签建议：

- parse_error：PDF 解析错误；
- metadata_error：公司、页码或文件错误；
- chunk_boundary：答案被切开；
- dense_miss：语义召回漏掉；
- bm25_miss：关键词召回漏掉；
- fusion_drop：融合后排名下降；
- rerank_drop：Reranker 把正例排掉；
- generation_error：上下文正确但答案错；
- citation_error：答案对但引用错；
- refusal_error：该答不答或不该答却回答。

第 3 部分 常见技术问题与设计说明

架构与业务

1. 为什么使用 RAG，不直接让大模型回答？

企业报告是私有且会更新的知识。RAG 可以动态更新知识、降低幻觉并提供可核对引用，不需要每次文档变化都重新微调模型。

2. RAG 和微调有什么区别？

RAG 主要解决知识注入、时效性和引用；微调主要改变模型行为、格式、风格和任务能力。金融事实优先 RAG，固定输出格式可以再用 SFT 辅助。

3. 原始项目和当前项目分别是什么？

原始项目是我提供的 7.17 实训代码；MyAI 是我在此基础上完成第一轮调优的版本。语雀资料只是技术参考。

4. 为什么项目叫金融报告助手，不叫金融政务双域？

因为当前真正建立索引并完成测试的是 10 份企业金融报告。原始项目有政务页面和政务 PDF，但当前不能声称完整覆盖两个知识域。

5. 系统完整流程是什么？

PDF 解析、清洗、切片、Embedding 和 FAISS 是离线流程；在线先 Dense 与 BM25 召回，再公司过滤和去重，Reranker 取 Top3，相关性判断后让 LLM 生成，最后校验并返回完整 PDF 页。

数据与切片

6. 为什么数据质量比换模型更重要？

如果正文重复、公司标签错误或页码映射错误，再强的 Embedding 和 LLM 也会基于错误证据回答。当前项目的跨公司错配就是数据构建问题，而不是模型能力问题。

7. 你怎么发现 1120/112 重复索引？

统计索引总记录数、标准化正文 hash 的唯一数以及每条正文关联的公司集合，发现 1120 条记录只有 112 条唯一正文，且同一正文被绑定到多家公司。

8. 为什么 Chunk 从 200/50 调到 500/80？

200 字容易拆散公司、年份、指标、数值、单位和解释。500 字更可能保留完整财务事实，80 字重叠减少边界丢失；它是当前基线，不代表理论最优。

9. Chunk 越大越好吗？

不是。大 Chunk 上下文完整但语义密度低、噪声多；小 Chunk 定位精准但容易断句。要用 Recall、MRR、答案完整性、Token 和延迟一起选。

10. 怎么处理 PDF 表格？

普通文本按段落切片；表格转成 Markdown 或 JSON，保留表名、行列标题、单位和页码；扫描件先 OCR；复杂图表可以用视觉模型提取。

11. 什么是父子切片？

小 Chunk 用于精准检索，命中后取所属父段落或完整页面给生成模型。它兼顾召回精度和上下文完整性。

Embedding 与向量库

12. Embedding 是什么？

把文本映射到稠密向量，使语义接近的文本在向量空间中距离更近。

13. 为什么使用 BGE-small-zh-v1.5？

中文检索效果、模型体积和 Mac 运行成本平衡较好，输出 512 维向量，对 112 个切片足够。

14. BGE 的 Query instruction 有什么作用？

短 Query 检索长 Passage 时，指令帮助模型明确任务是检索而非通用相似度。是否添加必须用开发集比较，文档端一般不加。

15. 余弦相似度和 L2 有什么关系？

向量 L2 归一化后，最小 L2 距离与最大余弦相似度排序等价；未归一化时不等价。因此需要明确 Embedding 是否 normalize。

16. 为什么使用 FAISS IndexFlatL2？

数据只有 112 个向量，Flat 能精确检索且速度足够，方便把问题归因到数据和 Embedding，而不是 ANN 近似误差。

17. 百万级向量怎么办？

使用 HNSW、IVF-PQ 或 Milvus/Qdrant，配合分区、元数据过滤、动态更新和权限控制，并在 Recall、延迟和内存间取舍。

18. HNSW 主要调什么？

M 影响图连接度和内存，efConstruction 影响建库质量与耗时，efSearch 影响查询召回与延迟。

BM25、融合与重排

19. 为什么 Dense 和 BM25 都需要？

Dense 擅长语义、同义改写和口语表达；BM25 擅长公司名、年份、金额、缩写等精确词，两者互补。

20. BM25 的核心思想？

结合 TF、IDF 和文档长度归一化。k1 控制词频饱和，b 控制长度惩罚。

21. 中文 BM25 最大的坑是什么？

中文没有天然空格，按空格切词会把长段落当成少量 Token。当前离线评测中，空白分词 BM25 Hit@10 只有 0.370。

22. 你准备如何修中文 BM25？

短期用字符 unigram+bigram，不依赖词典；中期比较 jieba 加金融词典；规模扩大后可使用 Elasticsearch 中文分析器。

23. 中文分词带来了多少提升？

第一版 27 题页面级评测中，BM25 Hit@10 从 0.370 提升到 1.000，MRR@10 从 0.189 提升到 0.932。要强调这是小规模开发集结果。

24. 为什么不能直接相加 Dense 分数和 BM25 分数？

一个是向量距离或相似度，一个是 BM25 分数，量纲和分布不同，直接相加没有稳定含义。

25. RRF 是什么？

Reciprocal Rank Fusion 按排名融合：每一路对文档贡献 $1/(c+rank)$ ，不依赖原始分数尺度。

26. RRF 一定提高效果吗？

不一定。当前字符 BM25 的 MRR 为 0.932，RRF 为 0.920，但 RRF 把 Hit@3 从 0.963 提高到 1.000。要看业务目标和 Bad Case，不能只说融合必然更好。

27. Embedding 和 Reranker 区别？

Embedding 是双编码器，Query 和文档分别编码，快，适合大规模召回；Reranker 是 Cross-Encoder，联合编码 Query-Document，交互更充分但慢，适合少量候选精排。

28. 为什么 Top10 后取 Top3？

Top10 用于候选覆盖，Top3 控制上下文噪声、Token 和生成成本。需要比较 TopK 5/10/20 与 TopN 1/3/5。

29. 怎么判断 Reranker 是否有效？

在同一候选集上比较重排前后 MRR、Recall@3、NDCG 和 Top1 Accuracy，同时看重排延迟。如果正例在 Top10 但被重排出 Top3，说明 Reranker 产生负作用。

30. 怎么微调 Reranker？

构造(query, positive, hard negative)。Hard Negative 来自当前 Dense/BM25 高排名但人工判错的页面，避免只使用随机负例。

评测

31. Hit@K 和 Recall@K 有什么区别？

Hit@K 只看是否至少命中一个正确页面；Recall@K 看全部相关页面找回多少。多文档比较题更需要 Recall。

32. Precision@K 是什么？

TopK 中相关页面的比例。Precision 低说明上下文噪声多。

33. MRR 适合什么场景？

适合单答案问答，强调第一个正确页面是否排在前面。

34. NDCG 适合什么场景？

相关性有多级标注时，例如完整答案页标 3、背景页标 1、不相关标 0。

35. 最终答案准确率怎么算？

数值题做单位归一化和字段比对；短答案用 EM/Token F1；长答案看 Correctness、Completeness、Relevance 和 Faithfulness。

36. Faithfulness 怎么测？

把答案拆成原子 Claim，计算有多少 Claim 能被最终上下文直接支持。

37. 为什么不能只用 BLEU/ROUGE ?

它们主要看文字重合，不能可靠判断数字、公司和因果关系是否正确，也不能判断引用是否支持答案。

38. 拒答怎么测？

加入 15%-25%无答案问题，计算拒答 Precision、Recall、F1 和无答案幻觉率。

39. 没有 Golden Set 能报准确率吗？

不能。几条 Demo 只能证明链路可用，不能代表整体准确率。

40. 当前系统准确率是多少？

目前只能报告：27 条可回答题的离线页面级召回结果，以及 3 题端到端冒烟测试 3/3 通过。没有完成完整端到端测试，所以不能报全局准确率。

41. 如何避免 LLM Judge 偏差？

固定 Rubric、交换 A/B 顺序、多 Judge 投票、人工抽检，并计算 Judge 和人工标注的一致率。

生成、幻觉与工程

42. temperature 为什么是 0.1？

金融事实问答追求稳定和忠实，低温度减少随机表达，但不能替代检索和 Faithfulness 评测。

43. 上下文正确但答案错怎么办？

检查 Prompt 约束、上下文顺序、Lost-in-the-Middle、单位换算、数值计算、模型能力和输出校验。

44. 如何降低幻觉？

提高召回和重排质量，设置无证据拒答，限制模型只使用上下文，做 Claim 级校验，并返回可核对引用。

45. 当前`validate\_answer`有什么不足？

只是检查答案里的数字和英文实体是否作为字符串出现在上下文，不能判断中文实体、单位等价、计算关系和语义蕴含；还存在重复提取数字代码。

46. FastAPI 为什么适合？

有 Pydantic 类型校验、OpenAPI 文档、异步能力和成熟部署生态，适合作为模型服务层。

47. 当前并发问题是什么？

async 路由内部使用同步 requests，网络等待会阻塞事件循环；本地 Embedding 计算也会占用执行线程。应改用 httpx.AsyncClient、线程池或任务队列。

48. 怎么监控 RAG？

记录 Trace ID、每阶段耗时、TopK、rank、score、Token、状态码、拒答率、引用命中率、点赞率和 p50/p95/p99 延迟。

49. 如何防 Prompt Injection？

把检索文档当数据而不是指令；系统 Prompt 明确优先级；过滤恶意片段；工具权限隔离；输出与引用审计。

50. 如果只有一周，最先改什么？

先接入中文 BM25 和阶段日志，再实现 RRF 与 Reranker 分数保存；同时扩充并冻结测试集，最后校准拒答阈值。没有评测，不应先盲目换大模型。

语雀/Git 资料延伸追问

51. 什么是 RAG 2.0？

它不是一个单独模型，而是一组比基础“向量检索+生成”更完整的方法，包括 Hybrid Search、Sparse/Dense 互补、Reranking、Query 改写、多跳检索、评测和反馈闭环。

52. Sparse Retrieval 和 Dense Retrieval 分别是什么？

Sparse 以词项为中心，如 BM25，擅长精确词；Dense 把文本映射为稠密向量，擅长语义和同义表达。混合检索利用二者互补。

53. Qwen3 Embedding 相对普通 Embedding 的技术重点是什么？

重点是 Instruction-aware、多语言 and 不同模型尺寸带来的精度/延迟权衡。是否替换 BGE 必须用项目开发集验证，不能只看公开榜单。

54. 什么是 InfoNCE？

一种对比学习损失，让 Query 与正例相似度增大、与 batch 中的负例相似度减小，温度参数控制分布尖锐程度。

55. 什么是 in-batch negative？

一个 batch 中，其他 Query 的正例可以作为当前 Query 的负例，降低显式构造负例的成本；但要注意假负例。

56. 为什么需要 Hard Negative？

随机负例过于简单。公司不同但指标相同、公司相同但年份不同的页面更能训练模型区分细粒度金融事实。

57. Qwen3 Reranker 和 Embedding 模型能互相替代吗？

不能。Embedding 适合预计算文档向量和大规模召回；Reranker 需要对每个 Query-Document 对联合计算，效果通常更精细但无法低成本扫描整个库。

58. FAISS 和 Milvus 怎么选？

FAISS 是单机向量检索库，适合当前小规模静态数据；Milvus 是向量数据库，适合更大规模、动态更新、过滤、持久化和多实例服务。当前 112 条使用 Milvus 是过度设计。

59. MAP 和 MRR 有什么区别？

MRR 只关注第一个相关结果；MAP 考虑每个相关结果出现位置的平均精度，更适合一个 Query 有多个相关文档的场景。

60. Context Recall 和 Faithfulness 分别属于哪一层？

Context Recall 属于检索层，检查标准证据是否被取回；Faithfulness 属于生成层，检查答案中的事实是否被最终上下文支持。前者高不代表后者一定高。

第 4 部分 项目技术速查

一句话项目

我在 7.17 单文档 RAG 原始项目上，调优了一个面向 10 份企业金融报告的混合检索问答助手，重点解决重复索引、跨公司错配、中文 BM25、引用追溯和分层评测。

关键数字

- 原始：1 份 PDF、26 个 Chunk、200/50。
- 当前：10 份 PDF、112 个唯一 Chunk、500/80、512 维。
- Dense：Top10。
- 当前 BM25：Top20，但中文空白分词有问题。
- Reranker：Top3。
- LLM：temperature 0.1、max_tokens 1024。
- 错误索引：1120 条记录、112 条唯一正文。
- 修复后：112 条记录、112 条唯一正文、跨公司错配 0。
- 第一版评测：32 题，27 可回答、5 无答案。
- Dense Hit@10：1.000，MRR：0.910。
- 空白 BM25 Hit@10：0.370，MRR：0.189。
- 中文字符 BM25 Hit@10：1.000，MRR：0.932。
- 字符 BM25 + Dense RRF Hit@3：1.000。
- 端到端只测 3 题：3/3，平均约 10.49 秒，不能说整体 100%。

六句话框架

1. 数据决定上限：解析、切片、元数据、去重先正确。
2. 粗召回追求不漏：Dense 负责语义，BM25 负责精确词。
3. 精排追求靠前：Cross-Encoder 把正确证据放进 Top3。
4. 生成必须有依据：低温度、拒答、校验和引用。

5. 评测必须分层：召回、重排、生成、拒答、端到端、延迟。
6. 没有冻结测试集不报整体准确率。

三个核心优化案例

案例 1：索引错配

回答对但引用错 → 打印中间结果 → 发现 1120/112 重复 → 修复构建与公司标签 → 错配降为 0。

案例 2：BM25 评测

不是“加了 BM25 就一定更好” → 单独测两路 → 空白分词 Hit@10 仅 0.370 → 中文字符分词提升到 1.000。

案例 3：完整页引用

小 Chunk 利于检索但不方便用户核对 → 模型仍用 Chunk → 前端展示命中 Chunk 所属完整 PDF 页。

项目表述注意事项

- 不说整体准确率 100% 或 95%；
- 不把离线 RRF 模拟说成已接入后端；
- 不把 3 题冒烟测试说成正式测试；
- 不说 Reranker 已经微调；
- 不说 MyAI 是原始项目；
- 不说金融政务双域已完成；
- 不说 SiliconFlow 模型是本地部署；
- 不说 FAQ/few-shot 已经形成成熟数据飞轮。

核心优化原则

当前最优先的不是盲目换更大的模型，而是把中文分词、融合、分数日志和 Golden Set 做好，用固定测试集证明每项改动的真实收益。

附录 A Golden Test Set 第一版

当前题集共 32 题：27 条可回答题、5 条无答案题。它是项目开发阶段的第一版基线，正式报告前需要逐条人工复核，并拆开发集和冻结测试集。

ID	问题	类别	标准来源
F001	滨江消费品有限公司 2021 年的营业收入是多少？	单文档数值	11_滨江消费品有限公司_report.pdf 第 1 页
F002	滨江消费品有限公司 2021 年的净利润是多少？	单文档数值	11_滨江消费品有限公司_report.pdf 第 1 页
F003	滨江消费品有限公司的资产负债率是多少？	单文档数值	11_滨江消费品有限公司_report.pdf 第 1 页
F004	澜赋科技有限公司 2021 年的营业收入和净利润分别是多少？	单文档多事实	12_澜赋科技有限公司_report.pdf 第 1 页
F005	澜赋科技有限公司 2021 年的现金流量是多少？	单文档数值	12_澜赋科技有限公司_report.pdf 第 1 页
F006	阳光传媒集团有限公司 2021 年的营业收入是多少？	单文档数值	13_阳光传媒集团有限公司_report.pdf 第 1 页
F007	阳光传媒集团有限公司 2021 年债务重组减少了多少负债？	单文档事件	13_阳光传媒集团有限公司_report.pdf 第 1 页
F008	美好家政服务服务有限公司 2018 年的营业收入和净利润是多少？	单文档多事实	14_美好家政服务服务有限公司_report.pdf 第 1 页

ID	问题	类别	标准来源
F009	美好家政服务有限 公司收购养家乐后 获得了多少股权？	单文档事件	14_美好家政服务有限公司_report.pdf 第 1 页
F010	蓝天旅游有限公司 2021 年的营业收入 是多少？	单文档数值	18_蓝天旅游有限公司_report.pdf 第 1 页
F011	蓝天旅游有限公司 2021 年的净利润是 多少？	单文档数值	18_蓝天旅游有限公司_report.pdf 第 1 页
F012	蓝天旅游有限公司 在 2021 年 9 月融资 了多少钱？	单文档事件	18_蓝天旅游有限公司_report.pdf 第 1 页
F013	绿源环保有限公司 2017 年的营业收入 和净利润分别是多 少？	单文档多事实	5_绿源环保有限公司_report.pdf 第 1 页
F014	绿源环保有限公司 2017 年收购绿能科 技后持有多少股 权？	单文档事件	5_绿源环保有限公司_report.pdf 第 1 页
F015	拓远科技有限公司 2021 年的总资产和 总负债是多少？	单文档多事实	6_拓远科技有限公司_report.pdf 第 1 页
F016	拓远科技有限公司 2021 年 8 月募集了 多少资金？	单文档事件	6_拓远科技有限公司_report.pdf 第 1 页
F017	医疗先锋股份有限 公司 2021 年的营业 收入和净利润是多 少？	单文档多事实	8_医疗先锋股份有限公司_report.pdf 第 1 页

ID	问题	类别	标准来源
F018	医疗先锋股份有限公司收购 A 医药连锁公司后获得了多少股权？	单文档事件	8_医疗先锋股份有限公司_report.pdf 第 1 页
F019	能源巨星有限公司 2017 年的营业收入和净利润分别是多少？	单文档多事实	9_能源巨星有限公司_report.pdf 第 1 页
F020	能源巨星有限公司收购绿色新能源公司的资产花了多少钱？	单文档事件	9_能源巨星有限公司_report.pdf 第 1 页
F021	ACME 研发有限公司 2019 年二氧化碳排放量和能源消耗分别是多少？	环境责任	3_ACME 研发有限公司_report.pdf 第 3 页
F022	滨江消费品有限公司推出绿色产品后销售额增长了多少？	环境责任	11_滨江消费品有限公司_report.pdf 第 3 页
F023	医疗先锋股份有限公司披露的二氧化碳排放量和能源消耗是多少？	环境责任	8_医疗先锋股份有限公司_report.pdf 第 3 页
F024	能源巨星有限公司的员工满意度达到多少？	社会责任	9_能源巨星有限公司_report.pdf 第 2 页
F025	2019 年 ACME 研发有限公司董事会新增了几位成员？	公司治理	3_ACME 研发有限公司_report.pdf 第 2 页

ID	问题	类别	标准来源
F026	滨江消费品有限公司与澜赋科技有限公司 2021 年的营业收入是否相同？分别是多少？	多文档比较	11_滨江消费品有限公司_report.pdf 第 1 页； 12_澜赋科技有限公司_report.pdf 第 1 页
F027	阳光传媒集团和医疗先锋在 2021 年谁的净利润更高？两家公司分别是多少？	多文档比较	13_阳光传媒集团有限公司_report.pdf 第 1 页； 8_医疗先锋股份有限公司_report.pdf 第 1 页
N001	滨江消费品有限公司 2024 年的营业收入是多少？	无答案-越界年份	应拒答
N002	蓝天旅游有限公司 2022 年的净利润是多少？	无答案-越界年份	应拒答
N003	苹果公司今天的股价是多少？	无答案-外部实时信息	应拒答
N004	请告诉我明天上海的天气。	无答案-域外问题	应拒答
N005	请写一段 Python 爬虫代码。	无答案-域外问题	应拒答

附录 B 项目发布前自检清单

- 能从项目摘要、技术架构和问题复盘三个层次完整说明项目。
- 能明确说出 7.17 是原始项目，MyAI 是自己调优后的版本。
- 能解释 1120/112 重复索引问题是如何定位和修复的。
- 能说明 Dense、BM25、RRF 和 Reranker 各自职责。
- 能手写 Hit@K、Recall@K、Precision@K 和 MRR 公式。

- 能解释为什么三题通过不能叫系统准确率 100%。
- 能说明 Chunk、TopK、Reranker TopN 和拒答阈值如何用开发集调。
- 能说清当前已经实现、离线模拟和下一步计划的边界。
- 能回答中文 BM25、Embedding 归一化、Hard Negative 和 Faithfulness。
- 能给出一周内的优化优先级，而不是只说换更大模型。

附录 C 评测工具位置

以下工具已经保存在 MyAI 项目中。按照当前要求，本次只生成文档，不继续运行全量评测。

```
evaluation/golden_test_set.jsonl # 32 条标准题
evaluation/evaluate_retrieval.py # Dense/BM25/RRF 离线召回评测
evaluation/evaluate_api.py      # 答案、引用、拒答和延迟评测
evaluation/README.md            # 使用说明
```